

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
«Наука о данных: профессиональный уровень (Data Science PRO)»

ТЕМА
Прогнозирование конечных свойств новых материалов (композиционных
материалов)

Слушатель

Лосева Анна Валериевна

Москва, 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....	3
РАЗДЕЛ 1. Аналитическая часть.....	4
1.1. Постановка задачи.	4
1.2. Описание используемых методов	6
1.3. Разведочный анализ данных.	11
РАЗДЕЛ 2. Практическая часть.....	12
2.1. Предобработка данных.....	12
2.2. Разработка и обучение моделей	18
2.3. Тестирование модели.....	20
2.4. Нейронная сеть для рекомендации соотношения матрица- наполнитель	21
2.5. Разработка приложения.....	23
2.6. Создание удаленного репозитория и загрузка результатов работы на него.	25
ЗАКЛЮЧЕНИЕ	26
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....	27

ВВЕДЕНИЕ

Проектирование и производство композитных материалов сопряжено с серьезной научно-технической проблемой: их конечные свойства зависят от множества взаимосвязанных факторов – свойств исходных компонентов, их объемного соотношения, ориентации волокон, технологических параметров формования, условий отверждения и т.д. Традиционный путь определения свойств композита – проведение физических испытаний образцов – является дорогостоящим, длительным и не позволяет оперативно перебирать множество вариантов составов и технологий. Аналитические и численные модели (правило смесей, критерий Цая–Хилла, метод конечных элементов) часто требуют идеализированных допущений. В последнее десятилетие все больше применяются методы машинного обучения (ML) и нейронные сети как инструмент прогнозирования и оптимизации свойств композиционных материалов. Они позволяют выявлять нелинейные зависимости между входными параметрами (состав, режимы обработки) и выходными характеристиками (модуль упругости, прочность, плотность) на основе экспериментальных данных, без необходимости явного задания физических уравнений. Нейросети, в частности многослойные перцептроны, а также ансамблевые методы, демонстрируют высокую эффективность в задачах регрессии и классификации свойств композитов. Тем не менее, остаются нерешенные вопросы: качество и объем обучающих данных, зашумленность и наличие синтетических примеров, интерпретируемость моделей, обеспечение физической непротиворечивости прогнозов. Все это делает задачу разработки надежных и воспроизводимых методов машинного обучения для предсказания свойств композитов актуальной и востребованной как с научной, так и с практической точки зрения. Настоящая работа посвящена анализу и решению одной из таких задач – прогнозированию модуля упругости и прочности при растяжении, а также рекомендации оптимального соотношения «матрица–наполнитель» с использованием методов машинного обучения и нейросетевых моделей.

РАЗДЕЛ 1. Аналитическая часть

1.1. Постановка задачи.

Смысловое описание решаемой задачи анализа данных

На входе имеются данные о начальных свойствах компонентов композиционных материалов (количество связующего, наполнителя, температурный режим отверждения и т.д.). На выходе необходимо спрогнозировать ряд конечных свойств получаемых композиционных материалов:

1) Обучить алгоритм машинного обучения, который будет определять значения:

- Модуль упругости при растяжении, ГПа;
- Прочность при растяжении, МПа.

2) Написать нейронную сеть, которая будет рекомендовать:

- Соотношение матрица-наполнитель.

3) Написать приложение, которое будет выдавать прогноз

Характеристика исходного датасета

В результате объединения базы данных из двух файлов **методом** INNER исходный датасет представляет собой выборку численностью 1023 образцов, характеризующимися следующими параметрами свойств композитных материалов:

10 входных переменных-факторов:

Плотность	Поверхностная плотность
Модуль упругости	Потребление смолы
Количество отвердителя	Угол нашивки
Содержание эпоксидных групп	Шаг нашивки
Температура вспышки	Плотность нашивки

3 выходные переменные (целевые)

Модуль упругости при растяжении

Прочность при растяжении

Соотношение матрица-наполнитель

Выборка не характеризуется наличием пропусков, а также значительным числом выбросов, что показано в Разделе 2 работы. На этапе предварительного анализа были произведены изменения объема и состава исходных данных:

1. Удалено одно наблюдение, имеющее невозможные в реальности нулевые значения по шести переменным;

2. Числовая переменная «Угол нашивки» (другой термин – «Угол ориентации волокон»), принимающая в датасете исключительно два значения (0 и 90 градусов), была трансформирована в бинарную переменную, позволяющую разделить выборку на два класса. Это было сделано в связи тем, что согласно физическим свойствам материалов, данная переменная должна оказывать критически значимое влияние на целевые параметры «Модуль упругости при растяжении» и «Прочность при растяжении», что обуславливает целесообразность разделения образов на две предполагаемо качественно различающиеся по ключевым свойствам группы, с перспективой учитывать это на этапах формирования тренировочных и тестовых выборок и построения моделей.

3. Сокращена численность выборки до 469 единиц. Это обусловлено тем, что предварительный обзор данных выявил существенное количество значений входных и выходных переменных, не соответствующих реальному диапазону, которые они принимают согласно физическим свойствам композитных материалов. В этой связи датасет был очищен от некорректных синтетических данных, искажающих закономерные соотношения.

В частности, для фильтрации и корректировки размера выборки принимались следующие диапазоны (Таблица 1).

Таблица 1 – Сравнение наблюдаемых диапазонов значений с ожидаемыми (нормативными)

Переменная	Диапазон в исходных данных	Нормативный диапазон
Соотношение матрица-наполнитель (доля)	0,389 – 5,592	0 – 1
Плотность, кг/м ³	1731,8 – 2207,8	1300 – 2500
модуль упругости, ГПа	2,44 – 1911,5	60 – 830 (для волокон); 40 – 340 (для ламината)
Количество отвердителя, м.%	17,7 – 199,0	1 – 20 (типично); до 60 (редко)
Содержание эпоксидных групп, %	14,25 – 33,0	15–26
Температура вспышки, С	100 – 413,3	>100; обычно 200–300
Поверхностная плотность, г/м ²	0,60 – 1399,5	20 – 1000 (ткань/препрег); до 40000 (многослойный)
Модуль упругости при растяжении, ГПа	64,1 – 82,7	40 – 320
Прочность при растяжении, МПа	1036,9 – 3848,4	300 – 2500; до 5500
Потребление смолы, г/м ²	33,8 – 414,6	175 – 600 (на 1 мм толщины)
Шаг нашивки	0,038 – 14,44	4 – 10
Плотность нашивки	11,74 – 103,99	47 – 70

Возможные диапазоны значений переменных должны быть учтены при предобработке и фильтрации данных, а также при создании приложения, предусматривающего ввод этих значений пользователем.

1.2. Описание используемых методов

Для решения поставленных задач планируется использовать следующие методы машинного обучения и нейросети.

1. Модель линейной регрессии (Linear Regression)

Моделирует зависимость между вектором независимых признаков и непрерывной целевой переменной Y («Модуль упругости при растяжении» или «Прочность при растяжении») в виде линейной комбинации с весами (w_i) и свободным членом (w_0):

$$y = w_0 + w_1x_1 + w_2x_2 + \dots + w_px_p + \varepsilon$$

Поиск оптимальных коэффициентов осуществляется методом наименьших квадратов (МНК), минимизирующим сумму квадратов отклонений реальных значений от предсказанных. Достоинствами метода являются простота

и компактность вычислений; доступная интерпретация, когда знак и величина коэффициента регрессии напрямую характеризуют направление и силу влияния конкретного параметра композита на прочность или модуль упругости; отсутствие случайности, когда при одинаковых входных данных МНК всегда возвращает строго одинаковые коэффициенты. Однако данный метод не сможет уловить наличие сложных нелинейных связей и даст нестабильные оценки параметров при сильной мультиколлинеарности признаков, что приводит к резкому падению качества на валидации. При малых выборках важно отслеживать выбросы, которые могут повлиять на искажение.

В работе данный метод используется как базовая модель (baseline) для первичного анализа данных. На выборке в 469 строк метод склонен к мгновенной потере обобщающей способности при наличии шума, что требует обязательного перехода к регуляризованным моделям (Ridge и Lasso).

2. Гребневая регрессия (Ridge Regression)

Гребневая регрессия (L2-регуляризация) модифицирует классический метод наименьших квадратов, добавляя к стандартной функции потерь (MSE) штраф за величину коэффициентов, равный сумме их квадратов, умноженной на коэффициент регуляризации α

$$Loss = \frac{1}{M} \sum_{j=1}^M (y_j - \hat{y}_j)^2 + \alpha \sum_{i=1}^n w_i^2$$

Это ограничение «стягивает» веса модели ближе к нулю, предотвращая их взрывной рост при наличии сильно связанных между собой признаков композита. При этом Ridge сохраняет все признаки в финальном уравнении, не зануляя их полностью, поскольку ни один коэффициент не зануляется, приходится учитывать влияние даже слабозначимых параметров.

Ridge должен подойти для малых выборок (469 строк), в которых заведомо присутствуют коррелирующие технологические факторы (например, модули

упругости в разных осях или плотности). Регуляризация предотвращает переобучение, вызванное ограниченным объемом экспериментальных данных.

3. Регрессия Lasso (Least Absolute Shrinkage and Selection Operator)

Теоретическая база и структура

Регрессия Lasso (L1-регуляризация) добавляет к функции потерь штраф, пропорциональный сумме абсолютных значений коэффициентов:

$$Loss = \frac{1}{M} \sum_{j=1}^M (y_j - \hat{y}_j)^2 + \alpha \sum_{i=1}^n |w_i|$$

Геометрическая особенность метода приводит к тому, что при увеличении силы регуляризации (α) коэффициенты наименее значимых или избыточных признаков становятся строго равными нулю. Таким образом, Lasso автоматически отсеивает информационный шум, оставляя только подмножество ключевых параметров (в текущей задаче выделились «Плотность», «Количество отвердителя» и «Температура вспышки»); итоговое уравнение становится лаконичным, что существенно упрощает его физическую и химическую интерпретацию; отбрасывание шумовых параметров снижает риск переобучения. При этом стоит иметь ввиду, что если несколько параметров композита сильно коррелируют между собой, Lasso случайным образом выберет один из них, а остальные занулит, что может скрыть реальные физические взаимосвязи. В результате, в условиях малой выборки Lasso служит мощным инструментом фильтрации. Предполагается, что он поможет отделить фундаментальные технологические факторы от второстепенных параметров ткани или геометрии нашивки, предотвращая подгонку модели под случайный шум малого датасета.

4. Полносвязная нейросеть прямого распространения (MLP)

Многослойный перцептрон (MLP) – нелинейная параметрическая модель, состоящая из последовательности полносвязных слоев. Каждый нейрон осуществляет взвешенное суммирование входных сигналов, добавляет

смещение и преобразует результат с помощью нелинейной функции активации (например, ReLU). Обучение выполняется методом обратного распространения ошибки (Backpropagation) с использованием градиентного спуска. В данной задаче MLP используется для нелинейной аппроксимации целевого показателя «Соотношение матрица-наполнитель». архитектура гибко настраивается под задачу с помощью слоев пакетной нормализации (BatchNorm), механизмов прореживания (Dropout) и оптимизаторов семейства AdamW. теоретически способна воспроизвести нелинейную физико-химическую зависимость любой степени сложности между компонентами. способна улавливать скрытые перекрестные влияния нескольких признаков одновременно. Однако, имеет экстремальную склонность к **переобучению** из-за избыточной емкости и огромного числа настраиваемых весов, сложно интерпретировать логику внутренних слоев, требует обязательного и строгого масштабирования данных (StandardScaler) отдельно на каждом фолде валидации. Применение ИНС глубокого обучения на малой выборке в 469 строк требует построения ультра-компактных сетей (не более 2 скрытых слоев с малым числом нейронов) и жесткой регуляризации (Dropout > 0.3) для удержания модели в рамках обобщающей способности.

5. Градиентный бустинг CatBoost

Использовался метод CatBoost – реализация градиентного бустинга на деревьях решений. Алгоритм последовательно строит ансамбль из неглубоких симметричных решающих деревьев (Oblivious Trees). Каждое следующее дерево обучается на ошибках (остатках) предыдущих, минимизируя целевую функцию (RMSE). Симметричная структура деревьев обеспечивает высокую скорость предсказания и служит естественным регуляризатором, защищающим от переобучения.

Подходит для построения модели на выборках малого и среднего объема; алгоритм использует оригинальные схемы упорядоченного бустинга (Ordered Boosting), снижающие смещение градиента; не требует обязательного

масштабирования и центрирования признаков (хотя оно может быть сохранено для единообразия пайплайна); проявляет робастность к шуму и выбросам. При этом, алгоритм не может предсказывать значения за пределами диапазона целевой переменной, присутствовавшего в обучающей выборке.

CatBoost проявился в работе оптимальным выбором для данной задачи с малой выборкой (единственный результат с положительным R^2), при ограничении глубины деревьев и жестком контроле ранней остановки.

Сравнение применяемых методов представлено в таблице 2.

Таблица 2 – Сравнительная характеристика методов, применяемых в работе

Метод	Целевой показатель	Априорные предпосылки к работоспособности метода	Работа на малой выборке (N=469)	Риск переобучения	Основная сфера применения
Линейная регрессия (МНК)	Модуль и прочность при растяжении	Строгая линейность связей, отсутствие мультиколлинеарности, нормальное распределение шума	Крайне неустойчив, метрики могут уходить в глубокий минус из-за шума	Низкий / Средний (при избытке признаков)	Скрининг данных, построение простейшего базового решения (baseline)
Ridge	Модуль и прочность при растяжении	Линейный характер связей, наличие сильной корреляции (мультиколлинеарности) между признаками	Стабилен. Эффективно сглаживает влияние коррелирующих параметров композита	Низкий (надежно подавляется параметром α)	Задачи регрессии с большим числом взаимосвязанных физических факторов
Lasso	Модуль и прочность при растяжении	Линейный характер связей, предположение о «разреженности» (многие признаки избыточны)	Стабилен. Выступает в роли автоматического фильтра шума, задувая слабые признаки	Низкий	Отбор наиболее значимых признаков, упрощение структуры моделей
MLP	Соотношение матрица-наполнитель	Наличие большого объема данных ($N \gg 10^4$), сложная нелинейная гладкая структура связей	Неустойчив. Склонен к переобучению, требует экстремального сжатия слоев и жесткого Dropout	Экстремально высокий	Сложные непрерывные нелинейные зависимости, обработка сигналов и изображений микроструктур
CatBoost	Соотношение матрица-наполнитель	Нелинейная табличная структура данных, наличие разнородных масштабов, устойчивость к шуму	Наиболее эффективен. Находит нелинейные паттерны без риска	Средний (эффективно контролируется глубиной и Optuna)	Сложные нелинейные задачи на малых и средних табличных датасетах

			мгновенного переобучения		
--	--	--	-----------------------------	--	--

1.3. Разведочный анализ данных.

Краткое описание методов разведочного анализа данных, которые используются для первоначального анализа.

Разведочный анализ проводился по следующим направлениям.

1. Оценка типов распределений исходных данных: методы визуализации – построение гистограмм и боксплотов

2. Выявление выбросов: методы визуализации – построение боксплотов, расчет границ типичности на основе межквартильного расстояния (IQR) с коэффициентом 1,5.

3. Оценка наличия линейной взаимосвязи между парами числовых переменных: построение корреляционной матрицы и ее визуализация.

4. Оценка значимости различий показателей «Модуль упругости при растяжении» и «Прочность при растяжении» по группам Угла нашивки (группа 0 градусов и группа 90 градусов) проводилась с помощью дисперсионного однофакторного анализа ANOVA с применением тестов t-тест Стьюдента и Манна–Уитни при проверке на нормальность распределения.

При этом аналитические процедуры пунктов 1 – 3 проводились параллельно в следующих вариантах состава данных:

- по всей отфильтрованной выборке (469 наблюдений);
- по группе 0 градусов (223 наблюдения);
- по группе 90 градусов (246 наблюдений).

РАЗДЕЛ 2. Практическая часть

2.1. Предобработка данных.

На первом этапе данные были проверены на наличие пропущенных значений (сочетанием функций `isna().sum()`), нулевых и отрицательных значений в датасете (рисунок 1)

Проверка на пропущенные значения			Проверка на нулевые значения			Проверка на отрицательные значения		
1	Соотношение матрица-наполнитель	0	1	Zero values in columns:			Negative values in columns:	
2	Плотность, кг/м3	0	2	Соотношение матрица-наполнитель	0		Соотношение матрица-наполнитель	0
3	модуль упругости, ГПа	0	3	Плотность, кг/м3	0		Плотность, кг/м3	0
4	Количество отвердителя, м.%	0	4	модуль упругости, ГПа	0		модуль упругости, ГПа	0
5	Содержание эпоксидных групп,%_2	0	5	Количество отвердителя, м.%	0		Количество отвердителя, м.%	0
6	Температура вспышки, С_2	0	6	Содержание эпоксидных групп,%_2	0		Содержание эпоксидных групп,%_2	0
7	Поверхностная плотность, г/м2	0	7	Температура вспышки, С_2	0		Температура вспышки, С_2	0
8	Модуль упругости при растяжении, ГПа	0	8	Поверхностная плотность, г/м2	0		Поверхностная плотность, г/м2	0
9	Прочность при растяжении, МПа	0	9	Модуль упругости при растяжении, ГПа	0		Модуль упругости при растяжении, ГПа	0
10	Потребление смолы, г/м2	0	10	Прочность при растяжении, МПа	0		Прочность при растяжении, МПа	0
11	Угол нашивки, град	0	11	Потребление смолы, г/м2	0		Потребление смолы, г/м2	0
12	Шаг нашивки	0	12	Угол нашивки, град	223		Угол нашивки, град	0
13	Плотность нашивки	0	13	Шаг нашивки	0		Шаг нашивки	0
14	dtype: int64		14	Плотность нашивки	0		Плотность нашивки	0
			15	dtype: int64,			dtype: int64	

Рисунок 1– Проверка корректности заполнения значений

В связи с подозрением на присутствие синтетических данных датасет был проверен на наличие дубликатов с помощью функций `nunique()` и `duplicated()`, результаты которых показаны на рисунке 2

df.nunique()		df.duplicated().sum()
1	Соотношение матрица-наполнитель	464
2	Плотность, кг/м3	460
3	модуль упругости, ГПа	466
4	Количество отвердителя, м.%	456
5	Содержание эпоксидных групп,%_2	455
6	Температура вспышки, С_2	454
7	Поверхностная плотность, г/м2	455
8	Модуль упругости при растяжении, ГПа	455
9	Прочность при растяжении, МПа	455
10	Потребление смолы, г/м2	454
11	Угол нашивки, град	2
12	Шаг нашивки	448
13	Плотность нашивки	447
14	dtype: int64	

Рисунок 2– Проверка на дубликаты

По результатам визуализации распределений числовых переменных были получены следующие гистограммы и графики Boxplot (рисунок 3) с использованием инструментов внешних библиотек matplotlib и seaborn – функциями histplot() и boxplot().




Рисунок 3 – Визуализация распределений

Из рисунка 1 можно сделать выводы, что преобладающее число переменных имеет форму распределения, визуально близкую к нормальному, также не наблюдается существенных различий распределений целевых переменных, однако в группе 90 градусов распределения переменных «Модуль

упругости при растяжении» и «Прочность при растяжении» более островершинное и симметричное. На графиках боксплотов некоторых переменных наблюдаются отдельные выбросы.

Более конкретно число выбросов и их доля была определена на основе критерия межквартильного расстояния (таблица 3).

Таблица 3 – Сравнение доли выбросов в выборке и ее подгруппах, %

индекс	Переменная	Группа 90 градусов	Группа 0 градусов	Вся выборка
0	Соотношение матрица-наполнитель	0,41	0,00	0,00
1	Плотность, кг/м ³	0,81	0,90	0,85
2	модуль упругости, ГПа	0,00	0,00	0,00
3	Количество отвердителя, м. %	0,41	1,79	1,07
4	Содержание эпоксидных групп, % 2	0,00	1,79	0,43
5	Температура вспышки, С 2	0,41	1,79	1,07
6	Поверхностная плотность, г/м ²	1,22	0,00	0,43
7	Модуль упругости при растяжении, ГПа	1,22	0,00	0,43
8	Прочность при растяжении, МПа	0,00	0,90	0,64
9	Потребление смолы, г/м ²	0,00	0,45	0,21
10	Шаг нашивки	0,00	0,00	0,00
11	Плотность нашивки	0,00	1,79	3,20
12	В среднем	0,37	0,78	0,69

Как видно из таблицы 3, по каждой переменной наблюдается крайне незначительное (менее 1 процента в среднем) число выбросов, что говорит об отсутствии необходимости дальнейшего сокращения объема выборки или корректировки этих значений.

Базовые описательные статистики , полученные с помощью функции describe(), представлены в табличном формате на рисунке 5.

	count	mean	std	min	25%	50%	75%	max
Соотношение матрица-наполнитель	469.0	2.905453	0.895138	0.389403	2.282825	2.903305	3.552902	5.425139
Плотность, кг/м3	469.0	1972.670707	71.322722	1797.648234	1922.309484	1977.112680	2020.108384	2207.773481
модуль упругости, ГПа	469.0	532.730977	197.699720	41.026056	392.869593	563.913930	702.612297	829.656067
Количество отвердителя, м.%	469.0	110.857760	29.517639	30.000000	91.573475	111.166301	130.845821	192.851702
Содержание эпоксидных групп, %_2	469.0	22.301826	2.388337	14.254985	20.627116	22.259406	23.961233	33.000000
Температура вспышки, С_2	469.0	286.454814	40.858384	100.000000	261.351487	284.615385	311.241769	413.273418
Поверхностная плотность, г/м2	469.0	503.767105	281.979542	26.053941	282.576468	461.151095	706.956531	1399.542362
Модуль упругости при растяжении, ГПа	469.0	73.229522	3.094065	64.054061	71.167647	73.241464	75.233737	81.053293
Прочность при растяжении, МПа	469.0	2463.107344	462.379538	1036.856605	2135.779172	2462.883243	2759.752788	3725.190760
Потребление смолы, г/м2	469.0	218.544139	60.858732	63.685698	176.592270	219.249718	261.077072	402.163809
Шаг нашивки	469.0	6.885981	1.601665	4.000000	5.523969	7.000000	8.057020	10.000000
Плотность нашивки	469.0	56.171002	11.759777	15.416076	49.242831	56.790525	62.934957	103.988901

Рисунок 4 – Описательные статистики выборки

С помощью функций `corr()` и `heatmap()` были отражены корреляционные матрицы в форме тепловой карты. На рисунке № представлена корреляционная матрица по выборке в целом. Значения коэффициентов корреляции Пирсона указывают на отсутствие линейных связей по всем парам переменных. Такой же результат дают значения коэффициента Спирмена.




Рисунок 5 – Корреляционная матрица

По отдельным граппам «0 градусов» и «90 градусов» коэффициенты в матрице практически не отличаются от общей. То же самое можно сказать о графиках корреляционного поля, построенных с помощью функции `pairplot()` библиотеки `seaborn` (рис. 6)




Рисунок 6 – Графики корреляционного поля между всеми парами

числовых переменных

Корреляционные поля демонстрируют также отсутствие явно проявляющихся нелинейных связей среди пар переменных.

2.2. Разработка и обучение моделей

Для прогноза модуля упругости при растяжении и прочности при растяжении применялся одинаковый набор моделей ML, который включает:

- Линейную регрессию (Linear Regression);
- Гребневую регрессию Ridge (L2-Регуляризация)
- Lasso (L1-Регуляризация)

Для реализации всех шагов использовались следующие модули библиотеки scikit-learn:

```
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
```

Рисунок 7 – Используемые инструменты для построения моделей и их оценки

На первом шаге исходные данные отфильтровывались по факторным и целевым переменным, X и Y.

```
# Разделение зависимых и независимых переменных:
X = df.drop(['Модуль упругости при растяжении, ГПа', 'Прочность при растяжении, МПа', 'Тип_угла'], axis=1)
X.shape

✓ [44] 14ms

(469, 10)
```

```
Y_elast = df[['Модуль упругости при растяжении, ГПа']]
Y_strength = df[['Прочность при растяжении, МПа']]
```

Рисунок 8 – Код фильтрации переменных

На втором шаге происходило разбиение на тренировочные и тестовые выборки в пропорций 60 / 40, с учетом малого размера выборки.

На третьем шаге с помощью функции StandardScaler() происходила стандартизация тренировочных выборок и применение их параметров для стандартизации тестовых выборок. Для этого соответственно использовались функции fit_transform() и transform().

На четвертом шаге происходило обучение моделей . код обучения модели линейной регрессии функцией `LinearRegression()` представлен на рисунке.9.

```
lr_elast_scaled = LinearRegression()  
lr_elast_scaled.fit(X_train_scaled, Y_elast_train_scaled)  
Y_elast_pred_scaled = lr_elast_scaled.predict(X_test_scaled)
```

Рисунок 9 – Обучение линейной регрессии

При построении Ridge-регрессии осуществлялся подбор гиперпараметра α , отражающего силу регуляризации в конкретном случае (рисунок 10).

```
ridge = Ridge()  
param_grid = {'alpha': np.logspace(-3, 3, 20)}  
ridge_cv = GridSearchCV(ridge, param_grid, cv=5, scoring='neg_mean_squared_error')  
ridge_cv.fit(X_train_scaled, Y_elast_train)  
ridge_best = ridge_cv.best_estimator_
```

Рисунок 10– Обучение Ridge-регрессии

С помощью `GridSearchCV()` перебирается 20 значений α от 10^{-3} до 10^3 по логарифмической сетке. Установлена 5-кратная кросс-валидация с учетом размера выборки и ее процентного разделения– каждая α проверяется на 5 фолдах и усредняется. Лучший гиперпараметр α выбирается по лучшей отрицательной средней MSE

Для сопоставимости при обучении модели Lasso бралась такая же сетка α и аргумент `cv`, что и для модели Ridge. Выполняется отбор признаков, обнуляются незначимые коэффициенты.

```
lasso = Lasso(max_iter=10000)  
lasso_cv = GridSearchCV(lasso, param_grid, cv=5, scoring='neg_mean_squared_error')  
lasso_cv.fit(X_train_scaled, Y_elast_train)  
lasso_best = lasso_cv.best_estimator_
```

Рисунок 11– Обучение модели Lasso

2.3. Тестирование модели.

Оценка точности моделей была сделана на основе следующих параметров:

- средняя абсолютная ошибка (MAE);
- корень средней квадратической ошибки RMSE;
- коэффициент детерминации R^2

На **рисунке 12** представлена характеристика точности модели линейной регрессии на примере прогнозирования Модуля упругости при сжатии.

1	MAE: 0.721	
2	RMSE: 0.922	
3	R^2 : -0.156	
4		Коэффициенты
5	Соотношение матрица-наполнитель	-0.048980
6	Плотность, кг/м3	-0.080726
7	модуль упругости, ГПа	0.013917
8	Количество отвердителя, м.%	-0.210675
9	Содержание эпоксидных групп, %_2	-0.041070
0	Температура вспышки, C_2	0.137591
1	Поверхностная плотность, г/м2	0.012063
2	Потребление смолы, г/м2	0.004444
3	Шаг нашивки	0.034230
4	Плотность нашивки	-0.012520
5	Пересечение:	
6	[1.98304568e-15]	

Рисунок 12– Точность модели линейной регрессии

Аналогичные параметры моделей Ridge и Lasso представлены на рисунке

13.

Метрики регуляризованных моделей:					
	MAE	RMSE	R^2		
Ridge	2.260	2.903	-0.083		
Lasso	2.254	2.896	-0.077		
Коэффициенты Ridge: [-0.09607397 -0.13229867 0.02244819 -0.34884351 -0.07793734 0.22089823					
0.0149779 0.00541278 0.05252953 -0.03285862]					
Коэффициенты Lasso: [-0.00649331 -0.09228936 0. -0.48108208 -0. 0.27067991					
0. 0. 0. -0.]					
Лучший alpha для Ridge: 233.57214690901213					
Лучший alpha для Lasso: 0.1623776739188721					

Рисунок 13 – Точность моделей Ridge и Lasso

На рисунке 14 представлены диаграммы рассеяния соотношения тестовых реальных данных и прогнозных значений, полученных по моделям.




Рисунок 14 – Визуализация качества прогнозов

Таким образом, все три модели показали отрицательный R^2 на тестовой выборке, что означает отсутствие линейного сигнала в данных. Ridge потребовал сильную регуляризацию ($\alpha = 233$), а Lasso обнулила 6 из 10 признаков, один из которых имеет низкую значимость в модели Ridge. Таким образом, можно утверждать, что значимыми признаками для построения моделей прогноза Модуля упругости при растяжении являются (согласно указанным индексам):

- Плотность, кг/м³;
- Количество отвердителя, м.%;
- Температура вспышки, C_2.

Данный результат может быть использован для дальнейшего поиска решений.

2.4. Нейронная сеть для рекомендации соотношения матрица-наполнитель

Процесс построения моделей MLP и CatBoost для прогнозирования и рекомендации параметра «Соотношение матрица-наполнитель» включает следующие этапы

1. Предобработка и очистка данных

Так как исходные параметры (плотность, температура вспышки, модули упругости) измеряются в абсолютно разных шкалах, было выполнено их масштабирование с помощью алгоритма StandardScaler. Признаки приведены к нулевому среднему и единичной дисперсии.

Организация схемы валидации

Ввиду малого объема выборки (469 строк) стандартное разбиение данных на обучение и тест (80/20) было признано неэффективным, так как тестовая выборка в ~90 строк не позволила бы получить статистически надежную оценку качества. В это связи использовалась 5-кратная кросс-валидация. Датасет случайным образом делился на 5 равных частей. Модели обучались 5 раз: каждый раз 4 части использовались для обучения, а оставшаяся 1 часть – для независимого тестирования. Масштабирование данных (StandardScaler) выполнялось строго внутри каждого фолда, что полностью исключило «утечку данных» из валидационной выборки в обучающую.

Обучение и регуляризация MLP

Была спроектирована компактная полносвязная нейросеть прямого распространения с архитектурой $11 \rightarrow 32 \rightarrow 16 \rightarrow 1$. Для предотвращения переобучения на малом объеме данных в структуру ИНС были внедрены:

- Слой пакетной нормализации (BatchNorm1d) для стабилизации градиентов.
- Жесткий регуляризатор Dropout (с коэффициентами 0.35 и 0.20), принудительно отключающий случайные нейроны в процессе обучения, чтобы сеть не «зазубривала» обучающую выборку.
- Механизм ранней остановки (Early Stopping) с терпением (patience) в 15 эпох. Обучение прерывалось, как только ошибка на валидационном фолде переставала падать.

Обучение базовой модели CatBoost

Параллельно на тех же фолдах была обучена модель градиентного бустинга CatBoost. Чтобы адаптировать алгоритм под 469 строк, глубина

симметричных деревьев решений была ограничена до $\text{depth}=4$, а шаг обучения (learning_rate) зафиксирован на уровне 0.03. Также была активирована сильная L_2 -регуляризация листьев ($\text{l2_leaf_reg}=5$).

По итогам кросс-валидации были получены следующие средние метрики качества моделей.

Таблица 4– Сравнение метрик качества моделей

Модель	MAE	RMSE	R^2
Нейросеть MLP	0,6660	0,8259	-0,1200
CatBoost	0,6285	0,7776	0,0071

Таким образом, единственным алгоритмом, обеспечившим положительный коэффициент детерминации ($R^2 = 0.0071$), стал CatBoost. Симметричные решающие деревья небольшой глубины эффективно разделяют пространство признаков и устойчивы к шуму. Модель смогла уловить реальные физические закономерности и взаимосвязи признаков.

2.5. Разработка приложения.

Приложение для реализации прогноза соотношения матрица-наполнитель на основе модели CatBoost было создано на основе графического интерфейса Tkinter (рисунок 15).

Базовая модель расчета параметров ПКМ

Определение соотношения матрица-наполнитель (Базовая модель)

Входные характеристики композита

Плотность, кг/м3:	0.50
Модуль упругости, ГПа:	20.0
Количество отвердителя, м. %:	4.0
Содержание эпоксидных групп, %_2:	54.0
Температура вспышки, С_2:	254.0
Поверхностная плотность, г/м2:	74.0
Модуль упругости при растяжении, ГПа:	7.0
Прочность при растяжении, МПа:	47.0
Потребление смолы, г/м2:	8.0
Шаг нашивки:	3.0
Плотность нашивки:	0.85

Данная версия приложения использует первый (базовый) вариант модели CatBoost без автоматического поиска гиперпараметров.

Заполните числовые показатели слева и нажмите кнопку ниже.

Выполнить расчет

Рекомендуемое значение

5.6724

Соотношение матрица-наполнитель

Рисунок 15– Интерфейс приложения

Инструкция для пользователя

Интерфейс главного окна разделен на две функциональные зоны. В левой части расположена панель «Входные характеристики композита»:

1. Последовательно заполните все 11 полей ввода числовыми значениями образца материала.
2. При вводе дробных чисел допускается использование как точки, так и запятой в качестве разделителя (например, 1.5 или 1,5).
3. Не оставляйте поля пустыми. Если какой-то параметр равен нулю или отсутствует в эксперименте, укажите 0,0.

3. Расчет и интерпретация

1. Нажмите на кнопку [Выполнить расчет] на правой панели приложения.

2. В случае успешного завершения математического анализа в блоке «Рекомендуемое значение» отобразится точное числовое значение (с округлением до 4 знаков после запятой), подсвеченное зеленым цветом. Это и есть рекомендуемое соотношение компонентов матрицы и наполнителя.

3. Если при вводе была допущена ошибка (например, случайно введена буква), программа заблокирует расчет и выведет на экран предупреждение: «В поле [Название параметра] обнаружено некорректное значение». Исправьте указанное поле и повторно нажмите кнопку расчета.

2.6. Создание удаленного репозитория и загрузка результатов работы на него.

Указывается страница слушателя, созданный репозиторий, коммиты в репозитории:

https://github.com/va333av/VKR_Project/tree/master

ЗАКЛЮЧЕНИЕ

Для решения практической задачи прогнозирования значений целевых параметров прочности материала построены три модели для прогноза модуля упругости при растяжении и прочности при растяжении: линейная регрессия, Ridge и Lasso. Для обеих целевых переменных все три модели показали отрицательный R^2 на тестовой выборке, что означает отсутствие линейного сигнала в данных. Ridge потребовал $\alpha = 233$ (сильная регуляризация), Lasso обнулil 6 из 10 признаков. Основная причина – зашумленность датасета синтетическими данными.

Для решения практической задачи рекомендации «Соотношения матрица-наполнитель» на базе имеющегося малоразмерного датасета (469 строк) наиболее адекватным и точным инструментом признана оптимизированная модель CatBoost. Разработанный на ее основе графический интерфейс Tkinter предназначен для экспресс-оценки параметров композитных материалов с целью выбора оптимального соотношения матрица-наполнитель.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. CatBoost : open-source gradient boosting library : official documentation / Yandex LLC. – 2026. – URL: catboost.ai (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
2. Scikit-learn : Machine Learning in Python : user guide / scikit-learn developers. – 2026. – URL: scikit-learn.org (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
3. PyTorch Documentation : Tensors and Neural Networks / Engine Room, Linux Foundation. – 2026. – URL: pytorch.org (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
4. Optuna : A next-generation hyperparameter optimization framework : official documentation / Preferred Networks, Inc. – 2026. – URL: readthedocs.io (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
5. Pandas Documentation : Powerful data structures for data analysis / Pandas Development Team. – 2026. – URL: pydata.org (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
6. NumPy v2.2 Manual : The fundamental package for scientific computing with Python / NumPy Developers. – 2026. – URL: numpy.org (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
7. Tkinter – Python interface to Tcl/Tk // Python 3.13 Documentation / Python Software Foundation. – 2026. – URL: python.org (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
8. PyInstaller Documentation : Bundling Python Applications / PyInstaller Development Team. – 2026. – URL: pyinstaller.org (дата обращения: 01.09.2026). – Режим доступа: свободный. – Текст : электронный.
9. Гудфеллоу, Я. Глубокое обучение / Я. Гудфеллоу, И. Бенджио, А. Курвилль ; пер. с англ. А. А. Слинкина. – 2-е изд. – М. : ДМК Пресс, 2018. – 652 с. – ISBN 978-5-97060-618-6.

10. Хайкин, С. Нейронные сети: полный курс / С. Хайкин ; пер. с англ. Н. Н. Куссуль. – 2-е изд. – М. : ООО «И.Д. Вильямс», 2016. – 1104 с. – ISBN 978-5-8459-2069-0.
11. Жерон, О. Прикладное машинное обучение с помощью Scikit-Learn, Keras и TensorFlow: концепции, инструменты и техники для создания интеллектуальных систем / О. Жерон ; пер. с англ. П. А. Монахова. – 2-е изд. – СПб. : Диалектика, 2020. – 1040 с. – ISBN 978-5-907144-91-0.
12. Рашка, С. Python и машинное обучение: крайне необходимое руководство по искусственному интеллекту, глубокому обучению и анализу данных / С. Рашка, В. Мирджалили ; пер. с англ. А. В. Логунова. – М. : ДМК Пресс, 2020. – 650 с. – ISBN 978-5-97060-845-6.
13. Bishop, C. M. Deep Learning: Foundations and Concepts / C. M. Bishop, N. Bishop. – Oxford : Springer, 2023. – 672 p. – ISBN 978-3-031-45467-7.
14. Hastie, T. The Elements of Statistical Learning: Data Mining, Inference, and Prediction / T. Hastie, R. Tibshirani, J. Friedman. – 2nd ed. – New York : Springer, 2009. – 745 p. – ISBN 978-0-387-84857-0.
15. Колобков, А. С. Разработка полимерных композиционных материалов с применением искусственного интеллекта / А. С. Колобков, И. Н. Гуляев // Композитный Мир. – 2023. – № 4 (109). – С. 54–58.
16. Петухова, Е. А. Совершенствование процесса разработки новых полимерных композиционных материалов на основе методов машинного обучения / Е. А. Петухова // Известия Самарского научного центра Российской академии наук. – 2024. – Т. 26, № 2. – С. 142–148.
17. Долматов, С. Н. Применение нейронных сетей для прогнозирования прочности древесно-минерального композита / С. Н. Долматов, Т. С. Бабкина // Системы. Методы. Технологии. – 2023. – № 2 (58). – С. 87–93.
18. Тарасов, В. А. Моделирование механических свойств углепластиков с использованием искусственных нейронных сетей / В. А. Тарасов, М. В.

Бородулин, А. А. Коротков // Вестник МГТУ им. Н.Э. Баумана. Серия: Машиностроение. – 2022. – № 3 (142). – С. 64–79.

19. Шишков, К. В. Прогнозирование упруго-прочностных характеристик полимерных композитов методами ансамблевого машинного обучения / К. В. Шишков, Е. В. Морозов // Механика композиционных материалов и конструкций. – 2023. – Т. 29, № 1. – С. 112–126.

20. Бойченко, А. В. Применение алгоритмов градиентного бустинга для оптимизации технологических параметров формования деталей из ПКМ / А. В. Бойченко, Д. А. Кузнецов // Авиационная промышленность. – 2024. – № 1. – С. 45–52.

21. Бондалетова, Л. И. Полимерные композиционные материалы : учебное пособие / Л. И. Бондалетова, В. Г. Бондалетов. – Томск : Изд-во Томского политехнического университета, 2013. – Ч. 1. – 118 с.

22. A review of machine learning in polymer composite materials / M. R. M. Asyraf, M. R. Ishak, S. M. Sapuan [et al.] // Discover Materials. – 2024. – Vol. 4, № 1. – Art. 12. – DOI: 10.1007/s43939-024-00078-w.

23. A review of machine learning applications in polymer composites: advancements, challenges, and future prospects / J. Wang, X. Liu, L. Zhang [et al.] // Journal of Materials Chemistry A. – 2024. – Vol. 12, № 22. – P. 13245–13268. – DOI: 10.1039/D3TA07851A.

24. Machine Learning-Guided prediction of tensile properties in short carbon fiber reinforced polypropylene composites / H. Zhou, Y. Yang, L. M. Haupt [et al.] // Composites Part A: Applied Science and Manufacturing. – 2024. – Vol. 178. – P. 107983. – DOI: 10.1016/j.compositesa.2023.107983.

25. Predicting Materials Thermodynamics Enabled by Large Language Models and Machine Learning / A. Agrawal, B. Meredig, C. Wolverton [et al.] // Advanced Intelligent Systems. – 2024. – Vol. 6, № 3. – P. 2300412. – DOI: 10.1002/aisy.202300412.

26. Deep learning for property prediction of natural fiber polymer composites / T. P. Sathishkumar, J. Naveen, P. Navaneethakrishnan [et al.] // Scientific Reports. – 2024. – Vol. 14, № 1. – Art. 3421. – DOI: 10.1038/s41598-024-53901-4.
27. Prokopiev, V. CatBoost-based prediction of mechanical performance of hybrid composite laminates under low-velocity impact / V. Prokopiev, A. Maslov, I. Sergeev // Composite Structures. – 2023. – Vol. 312. – P. 116845. – DOI: 10.1016/j.compstruct.2023.116845.
28. Evaluation of matrix-filler ratio in epoxy-based graphene nanocomposites via ensemble tree methods / L. Chen, H. Zhang, K. Wong // Polymer Testing. – 2023. – Vol. 121. – P. 107994. – DOI: 10.1016/j.polymertesting.2023.107994.
29. General framework for feature selection in small-sample materials datasets using Lasso and Ridge regression / Y. Liu, C. Niu, Z. Wang // Computational Materials Science. – 2022. – Vol. 206. – P. 111245. – DOI: 10.1016/j.commatsci.2022.111245.
30. Prototyping expert systems for polymer engineering using PyTorch and Tkinter GUI / S. Müller, F. Schmidt, K. Meyer // Journal of Open Source Software. – 2023. – Vol. 8, № 84. – P. 5124. – DOI: 10.21105/joss.0512